

Forecasting Extrínseco de Series Temporales en Procesos de Moldeo por Inyección

Regresión Sequence-to-Scalar *Multi-Output*

Juan Miguel Martínez Muñoz

Facultad de Ingeniería de la Universidad Nacional de Asunción (FIUNA)

21 de Julio

- **Complejidad Termodinámica:** Proceso cíclico altamente dinámico, sensible a variaciones y difícil de monitorear.
- **Limitación Actual:** La calidad del ciclo se valida post-producción o mediante simulaciones lentas.
- **Nuestra Propuesta:** Inferencia temprana mediante *Forecasting Sequence-to-Scalar*.
- **Objetivo:** Predecir 8 variables finales (ej. presión máxima, tiempos) proyectando solo los primeros 3 segundos del ciclo de inyección.




Figura: Proceso por inyección estándar.¹


¹Fuente: Animación de Proceso de Inyección (YouTube)

Dataset y Pipeline de Preprocesamiento

- **Origen de Datos:** Dataset industrial SKZ con observaciones temporales multivariadas de alta frecuencia.
- **Variables Objetivo:** 8 métricas críticas estáticas simultáneas (enfoque *Multi-Output*).
- **Ingesta y Truncamiento:** Fusión de archivos Parquet y recorte estratégico de la serie temporal a los primeros 3 segundos.
 - Captura la fase dinámica activa del polímero.
 - Permite una *alerta temprana* real sin esperar al final del ciclo (30s).
- **Escalado Estricto:** Aplicación de `StandardScaler` ajustado *únicamente* sobre el conjunto de entrenamiento para prevenir el *Data Leakage*.

Análisis de la Serie Temporal:

- Fase de inyección (pico de presión) ocurre en los primeros segundos.
- **Truncamiento (3 segundos):**
Captura la fase termomecánica más crítica.
- Permite inferencia temprana antes de finalizar el ciclo completo (30s).




Dinámica de presión frontal y trasera (Experimento 1).

Selección de Características:

- Identificación de multicolinealidad entre variables de presión.
- Depuración de variables redundantes del molde.
- **Reproducibilidad:** El dataset original validado se encuentra disponible para escrutinio.

► Acceso al Dataset



Mapa de correlación de variables escalares del proceso.

Machine Learning (Features)

Extracción manual de características (media, desviación, integral) a partir de los 3s:

- **Random Forest:** Ensamble arbóreo altamente resistente al sobreajuste (GridSearchCV).
- **XGBoost:** Boosting robusto para capturar relaciones no lineales complejas.

Deep Learning (Secuencias)

Inyección de la matriz secuencial cruda para aprendizaje de representaciones:

- **CNN-LSTM:** Red híbrida (extracción espacial convolucional + dependencia temporal).
- **FCN:** Red fully-convolutional 1D para mapas de características latentes.

Todos los modelos utilizan estrategia Multi-Output para proyectar las 8 variables.

Evaluación y Métricas (Presión Máxima de Masa)




Figura: Comparativa del Coeficiente de Determinación (R^2) por variable y arquitectura.

Evaluación y Métricas (Presión Máxima de Masa)

Evaluación sobre la variable mecánica crítica *MEAS_KM_Max MasDr [bar]*:

Modelo	RMSE	MAE	MAPE (%)	R^2
Random Forest	8.0629	6.9650	0.72 %	0.9967
XGBoost	28.3722	11.3060	0.95 %	0.9586
CNN-LSTM	60.6961	48.8004	4.61 %	0.8104
FCN	16.4526	14.0038	1.41 %	0.9861

*Nota: Valores extraídos para la variable *MEAS_KM_Max MasDr [bar]*. El ensamble Random Forest demuestra una captura casi perfecta de la varianza mecánica ($R^2 > 0,99$).

Visualizaciones: Real vs Predicción




Figura: Presión Max Masa (Alto ajuste)





Figura: Energía Consumida (Mayor dispersión)

Análisis de Residuales (Random Forest)

Random Forest - Presión Máx Masa



- **Prueba de Homocedasticidad (izq.):** Se aprecia un ligero incremento en la dispersión del error para valores predichos altos, atribuible al truncamiento a 3 segundos.
- **Distribución de Errores (der.):** Los residuos muestran una simetría razonable y cercanía a una distribución normal, validando la ausencia de sesgos sistemáticos graves.

- Se validó la viabilidad de la alerta temprana utilizando solo el $\sim 10\%$ de la curva temporal (3 segundos).
- **Hallazgo:** Los ensambles de Machine Learning (RF/XGBoost) alimentados con características manuales superaron al Deep Learning tabular en métricas de precisión general.
- El pipeline construido garantiza ausencia de fuga de información y es completamente extrapolable a inferencia en tiempo real (Edge AI).